XXI Jornada Científica
Faculdades Integradas de Bauru - FIB
ISSN 2358-6044
2026

PREVISÃO DE BATALHAS POKÉMON COM MÁQUINAS DE VETORES DE SUPORTE: GENERALIZAÇÃO PARA PERSONAGENS NUNCA VISTOS

Gustavo de Carvalho Vieira[1]; Alceu Ferreira dos Santos Neto; Anthony Gabriel Schirato Lourenço; Luan Carlos de Souza Ferreira; Lucas Miguel Moreno Rios; Ronaldo Cesar Dametto[2]
[1] Aluno de Ciência da Computação – Faculdades Integradas de Bauru – FIB – gustavovieira0512@gmail.com.
[2] Professor do curso de Ciência da Computação – Faculdades Integradas de Bauru – FIB – [e-mail do professor].

Grupo de trabalho: Ciência da Computação

Palavras-chave: aprendizado de máquina; máquinas de vetores de suporte; jogos digitais; simulação; inteligência artificial explicável.

Introdução: Jogos digitais constituem um campo tradicional de aplicação e avaliação de técnicas de Inteligência Artificial, por oferecerem ambientes com regras bem definidas e grande volume de dados (Yannakakis; Togelius, 2018). Em jogos de batalha, uma decisão recorrente do jogador é escolher um personagem sem saber se ele terá vantagem no confronto. A franquia Pokémon é um caso representativo: são mais de mil personagens, descritos por seis atributos numéricos (pontos de vida, ataque, defesa, ataque especial, defesa especial e velocidade) e por até dois de 18 tipos elementares, que conferem vantagens, resistências e imunidades. As Máquinas de Vetores de Suporte (SVM, do inglês Support Vector Machines) são classificadores que buscam o hiperplano de máxima margem entre as classes e admitem erros controlados por uma margem suave (Cortes; Vapnik, 1995). Com o uso de funções kernel, representam fronteiras de decisão não lineares (Boser; Guyon; Vapnik, 1992), característica desejável quando o resultado depende da interação entre variáveis, como velocidade e vantagem de tipo.

Objetivos: Investigar se um classificador SVM, utilizando apenas informações conhecidas antes da batalha, é capaz de prever o favorito de confrontos um contra um entre Pokémon que não fizeram parte do treinamento, superando regras simples e modelos lineares. Especificamente, buscou-se: construir uma base de batalhas reprodutível que abrangesse as nove gerações da franquia; avaliar, por experimentos controlados, o efeito do kernel, das variáveis de entrada, dos hiperparâmetros e do vazamento de dados; e disponibilizar o modelo em uma aplicação na qual dois jogadores se enfrentam e a decisão da IA é explicada com os conceitos do próprio SVM.

Relevância do Estudo: O trabalho aborda, em um contexto acessível, problemas centrais do aprendizado de máquina: construção de dados, prevenção de vazamento entre treino e teste (Kaufman et al., 2012), comparação com modelos de referência e generalização para exemplos novos. A aplicação torna visíveis conceitos abstratos, como fronteira de decisão, margem e vetores de suporte, o que favorece seu uso didático.

Material e métodos: Os atributos, tipos, gerações e golpes de 1.242 Pokémon jogáveis foram obtidos da base aberta PokéAPI (PokéAPI, 2023). Como o principal conjunto público de batalhas cobre apenas seis gerações e foi produzido por um algoritmo não documentado, desenvolveu-se um simulador baseado na fórmula de dano dos jogos principais, no nível 50, em que cada Pokémon utiliza os golpes de dano que efetivamente aprende, considerando poder, tipo, precisão, prioridade, acertos múltiplos, dano de retorno e alterações de atributos. Foram sorteados 40.000 confrontos, cada um simulado 21 vezes, e a variável-alvo indica o favorito (quem venceu a maioria das simulações), com classes equilibradas. Para evitar vazamento de dados, o treino utilizou batalhas entre Pokémon das gerações 1 a 6 (30.000) e o teste, entre Pokémon das gerações 7 a 9 (6.000), sem personagens em comum. Cada batalha foi descrita por 15 variáveis: diferença dos seis atributos, eficácia de tipo de cada lado e, a partir dos golpes que cada Pokémon aprende, a fração do HP adversário removida por turno, o número de golpes necessários para o nocaute e a existência de golpe de prioridade. Os dados foram padronizados com parâmetros do treino (Hsu; Chang; Lin, 2003) e o SVM foi implementado com a biblioteca scikit-learn (Pedregosa et al., 2011). Quatro experimentos controlados, com hipóteses registradas previamente, avaliaram: o kernel (E1); a inclusão das variáveis de golpes (E2); os hiperparâmetros C e gamma, escolhidos em uma validação entre as

gerações 1–4 e 5–6 (E3); o efeito de uma divisão aleatória, com vazamento (E4); e a comparação com KNN e Regressão Logística, com e sem padronização (E6). Como referência, foram usadas a classe majoritária, as regras “vence o mais rápido” e “vence o maior total de atributos” e a Regressão Logística, com acurácia, F1 e área sob a curva ROC (AUC).

Resultados e discussões: No conjunto de teste, as regras da velocidade e do maior total obtiveram 67,8% e 80,6% de acurácia. Com as variáveis de atributos e tipos, a Regressão Logística atingiu 85,6% e o SVM com kernel RBF, 86,6%, uma vantagem pequena do kernel não linear (E1). A inclusão das variáveis de golpes elevou o SVM para 92,6% (AUC de 0,977) e a Regressão Logística para 91,8% (E2), indicando que o ganho veio principalmente da informação fornecida ao modelo; a variável mais relevante foi o número de golpes para o nocaute. O ajuste de C e gamma não trouxe ganho mensurável (E3: 92,6%, com C = 10 e gamma = 0,05). Contrariando a hipótese, a divisão aleatória produziu acurácia equivalente (E4: 92,5%), pois as variáveis descrevem a batalha de forma relativa e não identificam o Pokémon, levando o modelo a aprender regras gerais em vez de memorizar personagens. Com as mesmas variáveis (E6), o SVM superou a Regressão Logística (91,8%) e o KNN (91,1%, k = 91); sem padronização, o KNN caiu para 81,5%, evidenciando a sensibilidade dos modelos baseados em distância à escala. Os erros (7,3%) concentraram-se em confrontos decididos pela sorte, com 31% de erro naqueles em que o favorito vence entre 30% e 70% das simulações, e em duelos nos quais ambos nocauteiam com um golpe. O modelo final foi integrado a uma aplicação web para dois jogadores que exibe, para cada batalha, a posição em relação à fronteira e à margem, a influência estimada de cada fator e os vetores de suporte que mais pesaram na decisão.

Conclusão: O SVM previu corretamente o favorito em 92,6% das batalhas entre Pokémon nunca vistos no treino, superando com folga as regras simples. As variáveis de entrada foram mais determinantes que a escolha do kernel ou o ajuste de hiperparâmetros, e o modelo aprendeu regras gerais de batalha, e não identidades de personagens. Como limitações, o simulador não representa habilidades, itens nem estratégias, de modo que o modelo aprende as regras simuladas, e não o jogo competitivo completo; além disso, a aleatoriedade das batalhas impõe um limite ao acerto possível. Como continuidade, propõe-se criar uma variável que combine velocidade, prioridade e nocaute.

Referências

BOSER, B. E.; GUYON, I. M.; VAPNIK, V. N. A training algorithm for optimal margin classifiers. *In*: WORKSHOP ON COMPUTATIONAL LEARNING THEORY, 5., 1992, Pittsburgh. **Proceedings** [...]. New York: ACM, 1992. p. 144-152. DOI: 10.1145/130385.130401.

CORTES, C.; VAPNIK, V. Support-vector networks. **Machine Learning**, v. 20, n. 3, p. 273-297, 1995. DOI: 10.1007/BF00994018.

HSU, C.-W.; CHANG, C.-C.; LIN, C.-J. **A practical guide to support vector classification**. Taipei: National Taiwan University, 2003. Disponível em: https://www.csie.ntu.edu.tw/~cjlin/papers/guide/guide.pdf. Acesso em: 28 out. 2026.

KAUFMAN, S. *et al*. Leakage in data mining: formulation, detection, and avoidance. **ACM Transactions on Knowledge Discovery from Data**, v. 6, n. 4, p. 1-21, 2012. DOI: 10.1145/2382577.2382579.

PEDREGOSA, F. *et al*. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.

POKÉAPI. **PokéAPI**: the RESTful Pokémon API. [*S. l.*], 2023. Disponível em: https://github.com/PokeAPI/pokeapi. Acesso em: 20 out. 2026.

YANNAKAKIS, G. N.; TOGELIUS, J. **Artificial intelligence and games**. Cham: Springer, 2018.