XXI Jornada Científica
Faculdades Integradas de Bauru - FIB
ISSN 2358-6044
2026

PREVISÃO DE BATALHAS POKÉMON COM MÁQUINAS DE VETORES DE SUPORTE: GENERALIZAÇÃO PARA PERSONAGENS NUNCA VISTOS

Gustavo de Carvalho Vieira[1]; Alceu Ferreira dos Santos Neto; Anthony Gabriel Schirato Lourenço; Luan Carlos de Souza Ferreira; Lucas Miguel Moreno Rios; Ronaldo Cesar Dametto[2]
[1] Aluno de Ciência da Computação – Faculdades Integradas de Bauru – FIB – gustavovieira0512@gmail.com.
[2] Professor do curso de Ciência da Computação – Faculdades Integradas de Bauru – FIB – [e-mail do professor].

Grupo de trabalho: Ciência da Computação

Palavras-chave: aprendizado de máquina; máquinas de vetores de suporte; jogos digitais; simulação; vazamento de dados.

Introdução: Jogos digitais constituem um campo tradicional de aplicação e avaliação de técnicas de Inteligência Artificial, por oferecerem ambientes com regras bem definidas e grande volume de dados (Yannakakis; Togelius, 2018). Em jogos de batalha, uma decisão recorrente do jogador é escolher um personagem sem saber se ele terá vantagem no confronto. A franquia Pokémon é um caso representativo: são mais de mil personagens, descritos por seis atributos numéricos (pontos de vida, ataque, defesa, ataque especial, defesa especial e velocidade) e por até dois de 18 tipos elementares, que conferem vantagens, resistências e imunidades. As Máquinas de Vetores de Suporte (SVM, do inglês Support Vector Machines) são classificadores que buscam o hiperplano de máxima margem entre as classes e admitem erros controlados por uma margem suave (Cortes; Vapnik, 1995). Com o uso de funções kernel, representam fronteiras de decisão não lineares (Boser; Guyon; Vapnik, 1992), característica desejável quando o resultado depende da interação entre variáveis, como velocidade e vantagem de tipo.

Objetivos: Investigar se um classificador SVM, utilizando apenas os atributos e os tipos de dois personagens, é capaz de prever o favorito de batalhas um contra um entre Pokémon que não fizeram parte do treinamento, superando regras simples e um modelo linear. Especificamente, buscou-se: construir uma base de batalhas reprodutível que abrangesse as nove gerações da franquia; identificar, por análise exploratória, os fatores que decidem os confrontos; comparar o SVM com modelos de referência; e disponibilizar o modelo em uma aplicação na qual dois jogadores escolhem seus personagens.

Relevância do Estudo: O trabalho aborda, em um contexto acessível ao público, problemas centrais do aprendizado de máquina: construção e documentação de dados, prevenção de vazamento de informação entre treino e teste, comparação com modelos de referência e avaliação da generalização para exemplos novos. Avaliar o modelo em personagens inéditos reproduz uma situação real dos jogos, nos quais novos personagens são lançados periodicamente, e evita resultados artificialmente otimistas, como os causados por vazamento de dados (Kaufman et al., 2012).

Material e métodos: Os atributos, tipos, gerações e golpes de 1.242 Pokémon jogáveis foram obtidos da base aberta PokéAPI (PokéAPI, 2023), após a remoção de formas cosméticas e repetidas. Como o principal conjunto público de batalhas cobre apenas seis gerações e foi produzido por um algoritmo não documentado, desenvolveu-se um simulador próprio baseado na fórmula de dano dos jogos principais, no nível 50, com fator aleatório de dano e golpes críticos. Cada Pokémon utiliza os golpes de dano que efetivamente aprende, considerando poder, tipo, precisão, prioridade, acertos múltiplos, dano de retorno e alterações de atributos, e escolhe a cada turno o golpe de maior dano esperado; habilidades, itens, golpes de status e trocas não foram simulados. Foram sorteados 40.000 confrontos, cada um simulado 21 vezes, e a variável-alvo indica se o primeiro Pokémon venceu a maioria das simulações, o que resultou em classes equilibradas. Para evitar vazamento de dados, o treino utilizou apenas batalhas entre Pokémon das gerações 1 a 6 (30.000 confrontos) e o teste, apenas batalhas entre Pokémon das gerações 7 a 9 (6.000 confrontos), sem personagens em comum. Cada batalha foi descrita por oito variáveis: a diferença entre os seis atributos dos dois Pokémon e o multiplicador de eficácia de tipo de cada lado, em escala logarítmica. Os dados foram padronizados com parâmetros estimados somente no treino (Hsu; Chang; Lin, 2003), e o SVM com

kernel RBF foi implementado com a biblioteca scikit-learn (Pedregosa et al., 2011). Como referência, foram avaliados a classe majoritária, as regras “vence o mais rápido” e “vence o maior total de atributos” e a Regressão Logística, por meio de acurácia, F1 e área sob a curva ROC (AUC).

Resultados e discussões: A análise exploratória indicou que a velocidade, isoladamente, decide 70,2% dos confrontos, e a maior soma de atributos, 82,2%. A vantagem de tipo mostrou efeito forte, mas não absoluto: com a maior vantagem, o primeiro Pokémon vence 82,5% das vezes e, com a maior desvantagem, 17,8%, pois o personagem em desvantagem frequentemente possui golpes de outros tipos. A aleatoriedade teve peso limitado: 71,1% dos confrontos apresentaram o mesmo vencedor nas 21 simulações e 5,7% foram equilibrados, o que impõe um teto ao acerto possível. No conjunto de teste, a classe majoritária obteve 51,0% de acurácia; a regra da velocidade, 67,8%; a regra do maior total, 80,6%; a Regressão Logística, 85,6% (AUC de 0,936); e o SVM, 86,6% (AUC de 0,935). O SVM superou com folga as regras simples, mas apresentou vantagem pequena sobre o modelo linear, indicando que boa parte da separação entre as classes é aproximadamente linear. Em uma versão anterior do simulador, com golpes genéricos de mesmo poder, o mesmo modelo atingia 92,1%: o realismo dos golpes tornou a previsão mais difícil, pois o modelo conhece apenas atributos e tipos. Um exemplo é o confronto entre Pikachu e Gyarados, previsto a favor do Gyarados, mas vencido pelo Pikachu com um golpe elétrico de alto poder. Nos confrontos equilibrados, o SVM errou 46,6% das previsões, valor próximo ao esperado pelo acaso.

Conclusão: O SVM previu corretamente o favorito em 86,6% das batalhas entre Pokémon nunca vistos no treino, superando regras baseadas em velocidade e em força geral, mas com ganho modesto sobre a Regressão Logística. Os resultados indicam que atributos e tipos explicam a maior parte dos confrontos e que a informação sobre os golpes de cada personagem é a principal lacuna do modelo. Como continuidade, serão incluídas variáveis derivadas dos golpes, comparados diferentes kernels e ajustados os hiperparâmetros por validação cruzada agrupada por personagem. Como limitação, o simulador não representa habilidades, itens nem trocas, de modo que o modelo aprende as regras simuladas, e não o jogo completo.

Referências

BOSER, B. E.; GUYON, I. M.; VAPNIK, V. N. A training algorithm for optimal margin classifiers. *In*: WORKSHOP ON COMPUTATIONAL LEARNING THEORY, 5., 1992, Pittsburgh. **Proceedings** [...]. New York: ACM, 1992. p. 144-152. DOI: 10.1145/130385.130401.

CORTES, C.; VAPNIK, V. Support-vector networks. **Machine Learning**, v. 20, n. 3, p. 273-297, 1995. DOI: 10.1007/BF00994018.

HSU, C.-W.; CHANG, C.-C.; LIN, C.-J. **A practical guide to support vector classification**. Taipei: National Taiwan University, 2003. Disponível em: https://www.csie.ntu.edu.tw/~cjlin/papers/guide/guide.pdf. Acesso em: 28 out. 2026.

KAUFMAN, S. *et al*. Leakage in data mining: formulation, detection, and avoidance. **ACM Transactions on Knowledge Discovery from Data**, v. 6, n. 4, p. 1-21, 2012. DOI: 10.1145/2382577.2382579.

PEDREGOSA, F. *et al*. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.

POKÉAPI. **PokéAPI**: the RESTful Pokémon API. [*S. l.*], 2023. Disponível em: https://github.com/PokeAPI/pokeapi. Acesso em: 20 out. 2026.

YANNAKAKIS, G. N.; TOGELIUS, J. **Artificial intelligence and games**. Cham: Springer, 2018.